

CIFAR-100 ResNet34 迁移学习项目报告

1. 项目目标

本项目基于 CIFAR-100 数据集，使用 ImageNet 预训练的 ResNet34 进行迁移学习训练。实验目标是在有限图像分辨率和类别数量较多的 CIFAR-100 任务上，通过两阶段训练、数据增强、分层学习率和动态学习率下降等策略，提升模型在测试集上的分类准确率。

2. 数据集与预处理

实验使用 CIFAR-100 pickle 格式数据，其中训练集包含 50,000 张图像，测试集包含 10,000 张图像，每张图像原始大小为 32x32，类别数为 100。

由于 ResNet34 使用 ImageNet 预训练权重，输入图像被 resize 到 224x224，并使用 ImageNet RGB 均值和方差进行标准化：

```
mean = [0.485, 0.456, 0.406]
std = [0.229, 0.224, 0.225]
```

训练阶段使用的数据增强包括：

```
RandomCrop(32, padding=4)
Resize(224, 224)
RandomHorizontalFlip
RandomRotation(10)
RandomAffine
ColorJitter
Normalize
RandomErasing
```

测试阶段只使用确定性预处理：

```
Resize(224, 224)
ToTensor
Normalize
```

这样可以保证评估结果稳定、可复现。

3. 模型结构

主模型为 ImageNet 预训练的 ResNet34：

```
models.resnet34(weights=models.ResNet34_Weights.IMAGENET1K_V1)
```

由于 CIFAR-100 是 100 分类任务，实验将原始 ImageNet 的 1000 类全连接层替换为 100 类输出：

```
model.fc = nn.Linear(model.fc.in_features, 100)
```

最终采用的主方案保留 ResNet34 的原始 ImageNet stem，即使用 7x7 stride=2 卷积和早期 max pooling，并将 CIFAR-100 图像放大到 224x224 输入。

4. 训练策略

实验采用两阶段迁移学习训练。

第一阶段冻结 backbone，只训练新初始化的分类头：

```
freeze_backbone = True
```

第二阶段解冻全部网络，对 backbone 和分类头使用不同学习率：

```
backbone_lr < head_lr
```

该策略的目的是保护 ImageNet 预训练特征，同时让新分类头更快适配 CIFAR-100。

训练过程中还加入了动态学习率下降：

```
ReduceLROnPlateau
monitor = test_loss
factor = 0.5
patience = 2
min_lr = 1e-6
```

当测试集 loss 多轮不再改善时，自动降低学习率，减少后期震荡。

5. 实验过程与结果

5.1 基础两阶段训练

最初使用 ResNet34 预训练模型进行两阶段训练，第二阶段解冻全部网络并使用分层学习率。该方案最高测试准确率约为：

```
test_acc = 0.7954
```

对应结果目录：

```
checkpoints_stage2/
```

5.2 加入数据增强并继续微调

在基础模型上加入适度数据增强后，从无增强训练得到的最好模型继续微调，测试准确率提升到：

```
test_acc = 0.8476
```

对应结果目录：

```
checkpoints_noaug_best_aug_scheduler/
```

这说明数据增强对泛化能力有明显帮助。

5.3 更低学习率继续微调

在上述模型基础上继续使用更小学习率微调：

```
backbone_lr = 0.000002
head_lr      = 0.00002
```

训练 5 轮后取得当前最佳结果：

```
epoch = 30
test_acc = 0.8522
test_loss = 0.7031
```

对应结果目录：

```
checkpoints_low_lr/
```

最佳模型文件：

```
checkpoints_low_lr/best_resnet34_cifar100.pt
```

该方案是当前项目中的最终最佳方案。

5.4 增大 weight decay 的对比实验

随后尝试在当前最佳模型基础上增大 weight decay：

```
weight_decay = 0.001
```

训练结果如下：

best test_acc = 0.8522

该结果与 checkpoints_low_lr 基本持平，没有进一步提升。因此最终未将更大的 weight decay 视为有效改进。

6. 未采用或失败的实验方案

6.1 Label smoothing

实验曾尝试单独加入 label smoothing。该方法理论上可以缓解过拟合和模型过度自信，但在当前已经较强的模型基础上继续训练时，测试准确率明显下降，未能带来有效提升。因此该方案被回滚。

6.2 Mixup + label smoothing

实验还尝试过同时使用 mixup 和 label smoothing。该组合在训练初期导致测试准确率明显低于当前最佳模型，短期内未表现出提升趋势。考虑到当前任务已经接近平台期，该方案没有被纳入最终训练流程。

6.3 更大 weight decay

将 weight decay 增大到 0.001 后，测试准确率与当前最佳方案持平：

0.8522 -> 0.8522

该方案没有降低最终误差，也没有带来新的最优结果，因此仅作为对比实验保留。

6.4 CIFAR 版 ResNet stem

后续实验尝试使用 CIFAR 版 ResNet stem，将 ResNet34 的第一层改为更适合 32x32 图像的 3x3、stride=1 卷积，并去掉早期 max pooling。

但在本实验设置下，该方案最高测试准确率约为：

test_acc = 0.7713

该结果明显低于保留原始 ImageNet stem 并使用 224x224 输入的方案：

ImageNet stem + 224x224 输入: test_acc = 0.8522

CIFAR stem + 32x32 适配: test_acc ≈ 0.7713

原因可能是：本项目依赖 ImageNet 预训练权重，修改 stem 会破坏预训练模型最前端的特征提取结构，使迁移学习收益下降。因此最终采用原始 ImageNet stem。

7. 最终模型与提交文件

当前最佳模型：

checkpoints_low_lr/best_resnet34_cifar100.pt

最佳结果：

test_acc = 0.8522

8. 总结

本项目最终证明，在 CIFAR-100 上使用 ImageNet 预训练 ResNet34 时，保留原始 ImageNet stem 并将输入 resize 到 224x224，比改用 CIFAR stem 更有效。本次实验得出的最佳训练路线为：

ImageNet 预训练 ResNet34

-> 冻结 backbone 训练分类头

-> 解冻全模型分层学习率微调

-> 加入适度数据增强

- > 使用动态学习率下降
- > 使用极低学习率继续微调

最终最佳测试准确率达到:

85.22%

该结果对应的模型为 checkpoints_low_lr/best_resnet34_cifar100.pt。